BANKING CONVERSION AI

Actividad 6 — Evaluación y validación estadística de clasificadores

Gestión de Proyectos de Inteligencia Artificial · Módulo 2 / Semana 7.

Contexto: institución bancaria portuguesa, contratación de depósitos a plazo. Fuente: UCI Bank Marketing (45,211 registros), licencia CC BY 4.0, DOI 10.24432/C5K306. Objetivo SMART y protocolo completos en el README.

Resumen ejecutivo

Se evaluaron regresión logística y Random Forest frente a un baseline con particiones separadas, validación cruzada estratificada de cinco folds y ajuste de umbral exclusivamente con validación. El objetivo de negocio es priorizar contactos comerciales bajo un presupuesto de llamadas, sin afirmar efecto causal sobre contrataciones.

Indicador test	Regresión logística	Random Forest
F1	0.3124	0.3545
Recall	0.6474	0.5756
ROC-AUC	0.7204	0.7392
Average Precision	0.3470	0.3838

Se preseleccionó **RandomForest** con umbral **0.12**. El test no se utilizó para elegir ese umbral. Las tasas A/B presentadas son HISTÓRICAS y proceden de simulación offline, no de una campaña aleatorizada prospectiva.

1. Problema, objetivo SMART y datos

Problema: la capacidad de llamadas es limitada. Se busca comparar modelos para ordenar contactos antes de realizar la llamada. Objetivo específico: evaluar tres algoritmos, matriz de confusión, ROC/AUC, umbrales y validación cruzada sobre Bank Marketing, con test reservado y una simulación A/B del 20% de capacidad; medir las diferencias y documentar límites de inferencia.

El conjunto contiene **45,211** observaciones, **5,289** conversiones históricas (11.70%) y 39,922 no conversiones. Se preservan el archivo original y SHA256, con 11 predictoras operativas plausibles antes del contacto.

Etapa	Registros	Objetivo
Train	27,126	Grid Search y CV estratificada
Validation	9,042	Selección de umbral y modelo
Test	9,043	Medición final, McNemar, bootstrap y A/B offline

Control de fuga y transformación

Se excluye **duration** porque no puede conocerse antes de una llamada; también contact/day/month/campaign ante ambigüedad de disponibilidad previa. Las 11 variables restantes incluyen historia bancaria y de campañas pasadas. Imputación, escalado y OneHotEncoder se ajustan dentro de Pipeline/CV. No existe identificador de cliente, por lo que no podemos excluir con certeza que una persona se repita entre particiones.

Otra limitación: los registros históricos del archivo antiguo son observacionales y su distribución puede diferir de campañas futuras. La prueba aleatoria no sustituye una partición por fecha ni datos prospectivos.

Criterios predefinidos

GridSearchCV maximiza Average Precision. El umbral operativo se selecciona en validación maximizando F2 sujeto a precision al menos 0.20, si es posible. La elección entre modelos maximiza F2 en validación, con desempate por AP de CV.

2. Matrices de confusión y métricas

Métrica test	Logística	Random Forest
Accuracy	0.667	0.755
Precision	0.206	0.256
Recall	0.647	0.576
F1 / F2	0.312 / 0.453	0.354 / 0.461
Especificidad	0.669	0.778
TN / FP / FN / TP	5343 / 2642 / 373 / 685	6216 / 1769 / 449 / 609

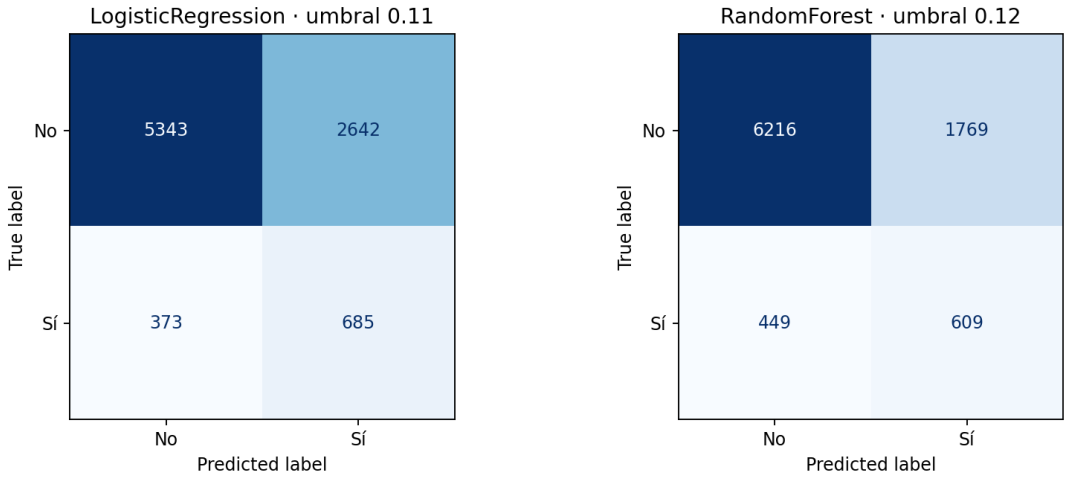


Figura 3. Matrices de confusión calculadas sobre test a los umbrales congelados.

Interpretación financiera: Random Forest detectó **609** conversiones históricas y omitió 449; la logística detectó 685 y omitió 373. Random Forest generó 1769 contactos priorizados sin conversión histórica frente a 2642 de la logística. Un falso positivo representa costo potencial de contacto, no fraude ni daño clínico. El umbral cambia la relación entre cobertura y eficiencia.

3. Curvas ROC/AUC y Precision-Recall

ROC-AUC mide capacidad discriminativa entre positivos y negativos a todos los umbrales, mientras Average Precision resume precisión-recall en una clase minoritaria (conversiones históricas). El modelo se comparó sobre los mismos 9,043 registros de test.

Figura 1. ROC por modelo (test)

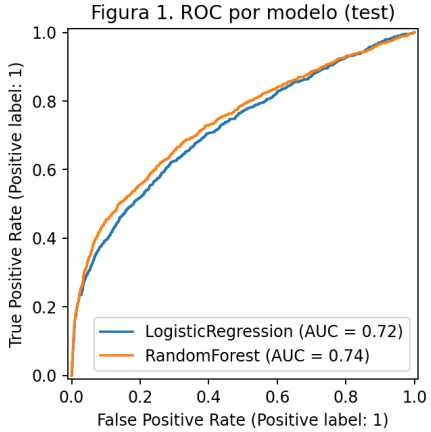
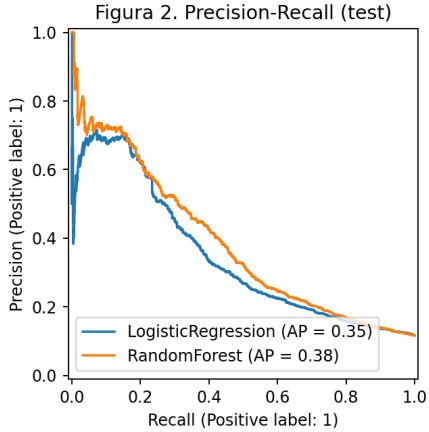


Figura 2. Precision-Recall (test)



Figuras 1 y 2. ROC y Precision-Recall obtenidas de probabilidades reales de prueba.

Random Forest logró ROC-AUC **0.7392** frente a 0.7204 de la logística, y AP **0.3838** frente a 0.3470. La ventaja en ranking no equivale por sí sola a un mayor número de contrataciones atribuibles a utilizar IA.

4. Umbral de decisión

Los umbrales de la evaluación fueron **0.11** (logística) y **0.12** (Random Forest). Se eligieron en validación, donde F2 fue 0.4640 y 0.4809, respectivamente. Los umbrales relativamente bajos permiten captar más positivos a costa de falsas alarmas. El umbral no fue reoptimizado con test.

5. Validación cruzada, baseline y significancia

Se entrenaron dos familias de algoritmos usando GridSearchCV y StratifiedKFold(5), con preprocesamiento sin fuga dentro del pipeline. Se seleccionaron parámetros maximizando Average Precision en train; la elección final quedó separada de test.

Modelo	AP media CV	F2 validación	Tiempo ajuste (s)
Logística	0.3435	0.4640	4.5
Random Forest	0.3670	0.4809	22.5

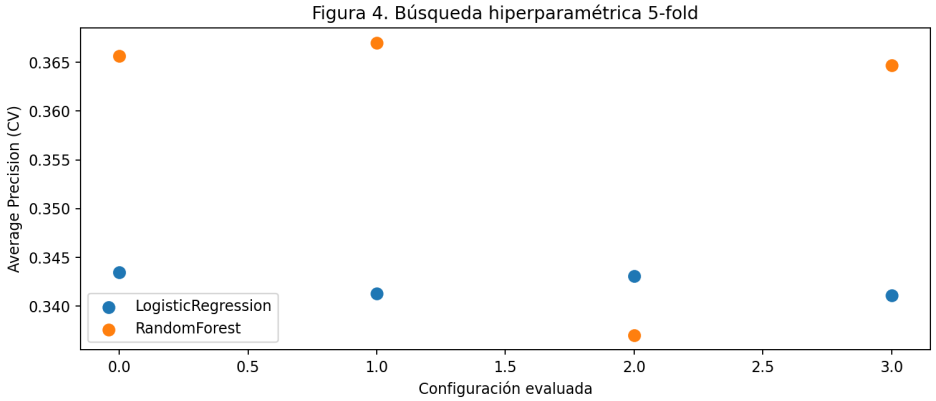


Figura 4. Average Precision de configuraciones en validación cruzada.

Baseline DummyClassifier: accuracy 0.883, recall 0.000 y F1 0.000. Una exactitud alta sin detección de conversiones es insuficiente.

Prueba exacta de McNemar sobre errores discordantes: 216 casos correctos solo para logística y 1013 correctos solo para Random Forest; p=1.1e-123. McNemar contrasta diferencias en errores, no en dinero ganado.

Bootstrap pareado (n=1000): diferencia F1(RF - logística) = 0.0421, IC95 percentil [0.0313, 0.0526]. La incertidumbre estadística no subsana sesgo de muestreo o drift.

6. Simulación A/B offline — no causal

Se dividió aleatoriamente el test en dos grupos disjuntos. A seleccionó 20% de contactos al azar; B seleccionó 20% según el score de Random Forest. Las etiquetas corresponden a contrataciones históricas observadas, no al resultado de asignar realmente esas políticas a clientes.

Medida	Política A	Política B
Observaciones del grupo	4521	4522
Contactos seleccionados	904	904
Contrataciones históricas	88	270
Tasa en seleccionados	9.73%	29.87%

Figura 5. Simulación A/B offline (NO efecto causal)

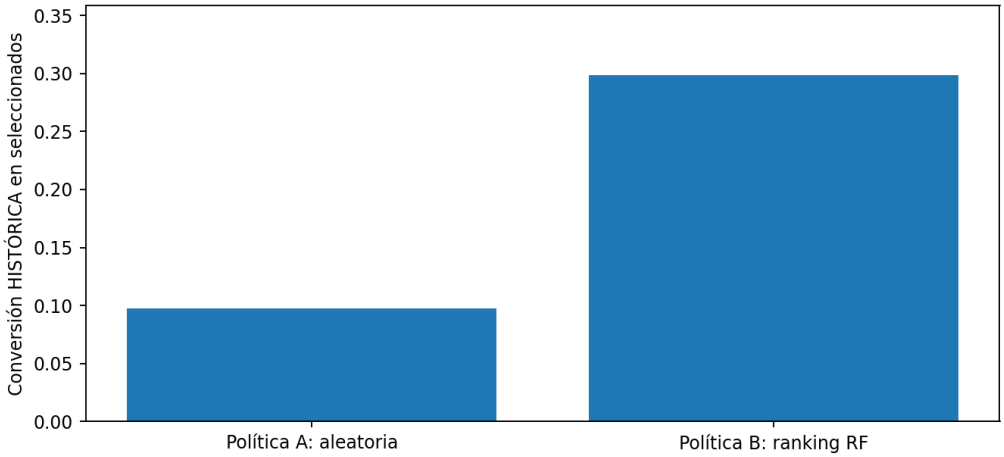


Figura 5. Tasa de respuesta histórica entre seleccionados; NO representa uplift causal.

Diferencia descriptiva de tasas: 20.13% (IC95 aproximado 16.58% a 23.69%); p exploratorio=6.5e-27. El contraste de proporciones entre observaciones seleccionadas no estima causalidad: existe sesgo de selección condicionado al score y no hay contrafactual de no llamar.

Diseño para una prueba real

Aleatorizar por cliente único, definir campaña y período prospectivos, misma capacidad por grupo, métrica primaria pre-registrada, control de interferencia, consentimiento y verificación legal, tamaño de muestra basado en potencia y reglas de paro. Comparar por intención de tratar con auditoría de equidad y monitoreo temporal.

7. Recomendación de negocio y límites

Modelo preseleccionado en validación: **RandomForest** (F2 validación 0.4809). Logística obtiene mayor recall en test, por lo que una institución más adversa a perder clientes potenciales podría preferirla, pese a su menor precisión y F1. La decisión debe incorporar presupuesto, costo por llamada y valoración de oportunidades perdidas, aún no cuantificados con datos reales.

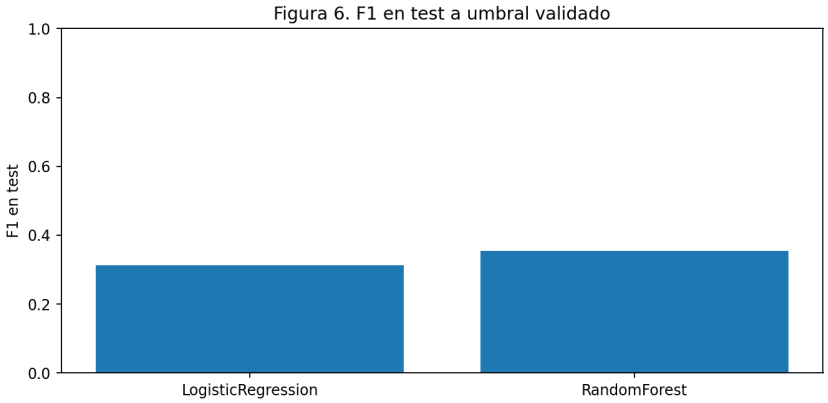


Figura 6. Diferencia observada en F1 sobre conjunto de prueba.

8. Evidencias, deuda técnica y Trello

Trazabilidad: código, notebook ejecutado, CSV original, splits, matrices, curvas, hipótesis y exportaciones reproducibles en GitHub. Tablero Trello: Banking Conversion AI — Actividad 6 (el profesor requiere acceso a un tablero privado o capturas genuinas adjuntas).

Limitaciones: datos observacionales antiguos, cambios de campaña, ausencia de ID de cliente para deduplicación, variables sensibles o correlacionadas con características demográficas, falta de calibración económica y ausencia de validación prospectiva. Mejoras MLOps: monitorizar drift, calibración, precisión por segmento, trazabilidad de datos, umbral y equidad; conservar supervisión humana.

Declaración de uso de IA y referencias

ChatGPT: asistencia en diseño experimental, código, documentación, tablero Trello y auditoría de resultados. Las métricas proceden de ejecución reproducible, sin valores generados manualmente.

Moro, S., Rita, P. y Cortez, P. (2014). Bank Marketing [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5K306

Código y evidencia: https://github.com/isaaccg88/BankingConversion-AI-Activity6